Immobilier et performance énergétique en France

Note de projet. Cours Python pour la data science, ENSAE Paris

1. Objet de la note

Cette note décrit le projet, la façon dont les données ont été collectées et reliées entre elles, et le travail d'analyse qui reste à faire. La méthode est présentée dans l'ordre où elle doit être appliquée. La note se termine par les limites connues du projet.

2. Contexte

Lors de la vente d'un logement en France, le vendeur doit fournir un diagnostic de performance énergétique (DPE). Ce diagnostic classe le logement de A, pour un logement très économe en énergie, à G, pour un logement très énergivore. Les logements classés F et G sont couramment appelés « passoires énergétiques ». La méthode de calcul du DPE a été réformée le 1er juillet 2021 (décret n° 2020-1609) ; depuis cette date, le diagnostic est opposable, c'est-à-dire que l'acheteur peut se retourner contre le vendeur s'il est erroné.

La loi Climat et résilience du 22 août 2021 (loi n° 2021-1104) a fixé un calendrier de contraintes pour les passoires énergétiques. Les loyers des logements classés F et G sont gelés depuis le 24 août 2022 (décret n° 2022-1079). Depuis le 1er janvier 2025, un logement classé G ne peut plus être proposé à la location. Les logements classés F seront concernés en 2028 et les logements classés E en 2034.

Ces règles peuvent peser sur le prix de vente. Un acheteur qui sait qu'il devra faire des travaux, ou qu'il ne pourra pas louer le logement, peut proposer un prix plus bas. Les travaux publiés sur la période 2016 à 2021 montrent déjà qu'un logement mieux classé se vend plus cher qu'un logement comparable classé G (Chareyron, 2026). La période 2022 à 2025 est particulièrement intéressante, puisqu'elle couvre l'entrée en vigueur des interdictions de location.

3. Problématique

Le projet répond à deux questions. La première : à caractéristiques comparables, un logement mieux classé au DPE se vend-il plus cher ? La seconde : l'écart de prix entre les étiquettes a-t-il changé entre 2022 et 2025, et varie-t-il selon les territoires ?

L'analyse porte sur la France métropolitaine. Elle est descriptive : elle mesure des écarts de prix entre logements comparables, sans chercher à démontrer qu'une étiquette ou une loi est la cause de ces écarts.

4. Données

4.1 Les sources

Le projet repose sur trois bases publiques.

- **Les Demandes de valeurs foncières (DVF)**, publiées par la direction générale des Finances publiques, dans leur version géolocalisée diffusée sur data.gouv.fr. Elles recensent toutes les ventes immobilières, avec le prix, la date, l'adresse, le type de bien et la surface. Chaque vente est localisée par les coordonnées du centre de sa parcelle cadastrale. L'Alsace et la Moselle n'y figurent pas, car elles relèvent d'un régime foncier particulier.
- **La base des DPE des logements existants**, publiée par l'ADEME. Elle contient les diagnostics réalisés depuis le 1er juillet 2021, avec la date, la surface habitable, la période de construction et l'étiquette du logement. L'adresse de chaque diagnostic est rapprochée de la Base Adresse Nationale, qui lui attribue des coordonnées et une note de fiabilité.
- **Le comparateur de territoires de l'Insee**, qui fournit des indicateurs par commune (population, revenus, structure du parc de logements).

Le prix ne figure que dans DVF et l'étiquette que dans la base de l'ADEME. Pour étudier le lien entre les deux, il faut retrouver, pour chaque vente, le diagnostic du même logement. Cette opération s'appelle un appariement. Elle est délicate, car les deux bases ne partagent aucun identifiant de logement.

Deux mots doivent être bien distingués dans la suite. Un **DPE** désigne un diagnostic, c'est-à-dire une ligne de la base de l'ADEME : il a été réalisé pour un logement précis, à une date précise, et porte un numéro unique. L'**étiquette** est la lettre, de A à G, inscrite sur ce diagnostic. Des milliers de logements différents ont la même étiquette, mais chacun a son propre DPE. Un même logement peut aussi avoir plusieurs DPE au fil du temps, par exemple avant et après des travaux, ou quand un diagnostic erroné est refait ; la base indique alors quel DPE en remplace un autre.

4.2 Des sources aux fichiers finaux

Le traitement est entièrement automatisé en Python et se déroule en cinq étapes, résumées dans la figure 1. Les données sont d'abord téléchargées depuis leurs sites officiels et conservées telles quelles. Elles sont ensuite nettoyées séparément. Les ventes et les diagnostics sont alors appariés, un département après l'autre, pour limiter la mémoire nécessaire. Le traitement produit enfin des fichiers au format Parquet, un format compressé adapté aux gros tableaux, ainsi qu'un journal qui enregistre le taux d'appariement de chaque département. Le traitement peut être relancé à tout moment et donne le même résultat.

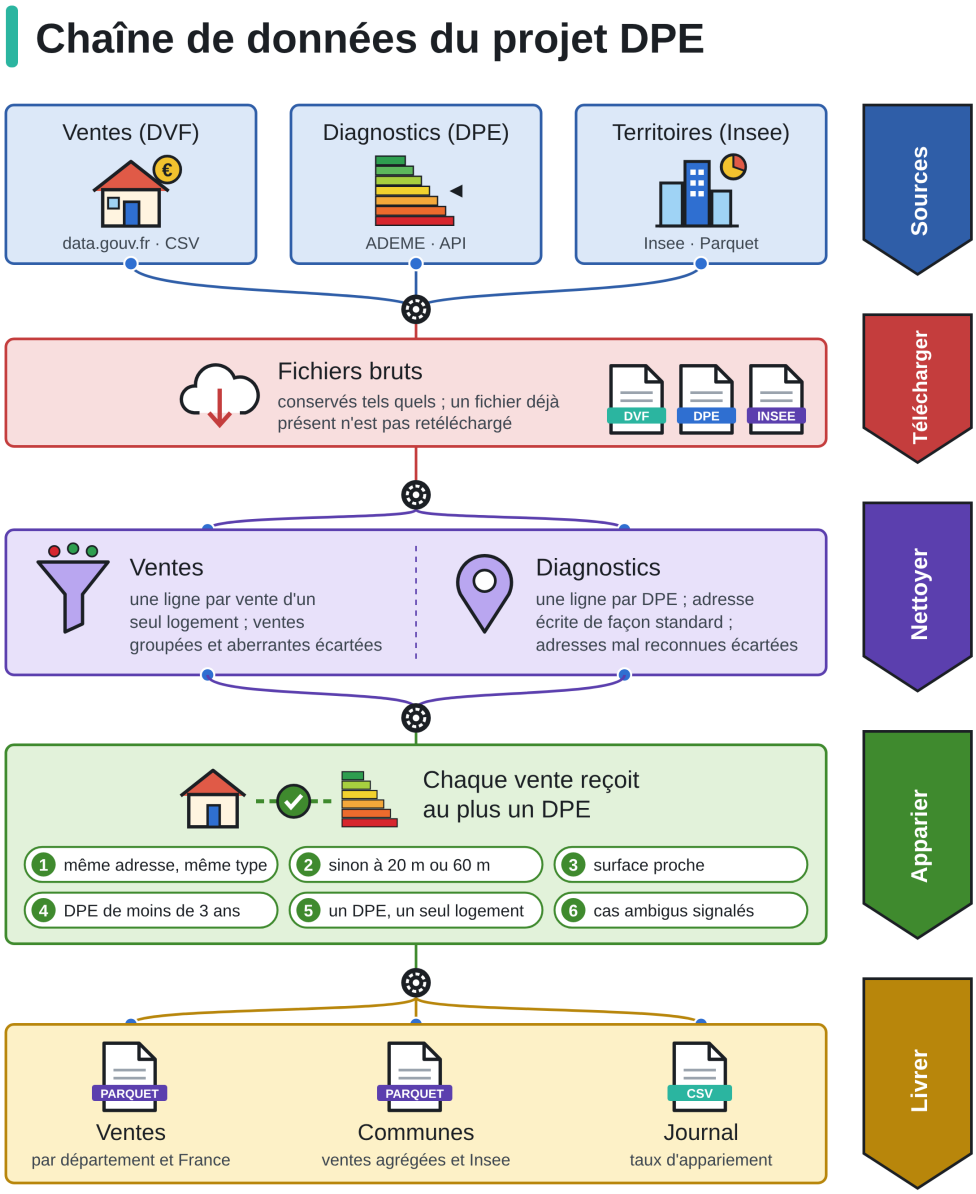


Figure 1. Chaîne de traitement, des sources publiques aux fichiers d'analyse

4.3 Le nettoyage des ventes

Une ligne de DVF ne correspond pas toujours à une vente d'un logement. Une même vente peut regrouper plusieurs biens, par exemple deux appartements ou un appartement et un commerce, pour un prix global. Comme ce prix ne peut pas être attribué à un logement précis, on ne garde que :

- les mutations de type « Vente » : les ventes sur plan, les échanges, les adjudications et les expropriations sont écartées ;
- les ventes portant sur un seul logement, maison ou appartement, éventuellement accompagné de dépendances comme une cave ou un garage, et sans local d'activité ;
- les logements de 9 à 400 m^2 vendus au moins 10 000 euros ;

- les prix au m^2 compris entre le 1er et le 99e centile de leur département et de leur type de bien, pour écarter les valeurs aberrantes.

Pour les appartements, on utilise la surface « loi Carrez » du lot quand elle est renseignée, car c'est la surface mesurée lors de la vente.

4.4 L'appariement des ventes et des diagnostics

Nous avons ensuite apparié ces ventes aux diagnostics selon six règles :

1. **Même adresse et même type de logement.** On cherche d'abord un DPE situé à la même adresse que la vente (commune, voie, numéro) et portant sur le même type de logement. Avant de comparer les adresses, on les écrit toutes de la même façon, car les deux bases ne les notent pas de la même manière : « AV DU GAL DE GAULLE » dans DVF, « Avenue du Général de Gaulle » dans la base de l'ADEME. Cette règle reprend celle de l'étude de référence (Chareyron, 2026). Comparer seulement les fiches qui partagent une même clé est une pratique classique de l'appariement de fichiers, appelée blocage (Christen, 2012).
2. **À défaut, un DPE tout proche.** Quand l'adresse ne permet pas de conclure, par exemple parce que le numéro manque ou que la voie est écrite trop différemment, on cherche un DPE à moins de 20 mètres pour un appartement et de 60 mètres pour une maison. Ces seuils s'expliquent par la façon dont chaque base localise les logements. DVF place la vente au centre de la parcelle cadastrale, alors que la base de l'ADEME place le diagnostic au point de l'adresse, en général devant l'entrée. Pour un même logement, les deux points ne coïncident donc pas. Un immeuble occupe le plus souvent une petite parcelle : le centre de la parcelle est proche de l'adresse, et un rayon de 20 mètres suffit. Un rayon plus grand risquerait d'atteindre l'immeuble voisin, dans des rues où les bâtiments sont serrés. Une maison est souvent entourée d'un jardin : le centre de la parcelle peut se trouver à plusieurs dizaines de mètres de l'adresse, d'où un rayon de 60 mètres. Ces deux valeurs sont des choix de l'équipe, vérifiés sur quelques départements ; elles ne viennent d'aucune norme publiée. Les ventes appariées de cette façon sont repérées, pour pouvoir les retirer lors des vérifications.
3. **Une surface proche.** On compare la surface du logement vendu, indiquée dans DVF, à la surface habitable du logement diagnostiqué, indiquée dans la base de l'ADEME. Elles doivent être proches, avec un écart d'au plus 10 % pour un appartement et 20 % pour une maison. On n'exige pas l'égalité, car les deux surfaces ne sont pas mesurées de la même façon. Celle du DPE est mesurée par le diagnostiqueur. Celle de DVF est la surface Carrez pour un appartement, et pour une maison la surface bâtie connue de l'administration fiscale, qui peut ne pas tenir compte d'une extension ou d'un aménagement récent. C'est pourquoi la tolérance est plus large pour les maisons. La surface sert aussi à choisir entre plusieurs DPE à la même adresse, comme le fait le service statistique du ministère de la Transition écologique dans ses propres appariements (SDES, 2022).

4. **Un DPE établi avant la vente, depuis moins de trois ans.** Le DPE doit être remis à l'acheteur : il est donc établi avant la vente. La loi le rend valable dix ans, mais nous retenons un délai de trois ans au plus. Plus le diagnostic est ancien, plus il est probable que des travaux aient été faits entre-temps, comme un changement de chaudière ou une isolation, et que l'étiquette connue de l'acheteur soit différente. En pratique, un vendeur fait réaliser le DPE au moment de la mise en vente. Ce délai pèse peu sur le nombre de ventes appariées : la base ne contient que des DPE établis depuis juillet 2021, si bien qu'aucun DPE de la base n'a plus de quatre ans et demi au moment d'une vente de 2022 à 2025. Si plusieurs DPE conviennent, on garde le plus récent, comme Zitouni (2025).
5. **Un DPE pour un seul logement.** Un DPE décrit un seul logement : la même ligne de la base de l'ADEME ne peut donc pas être attribuée à deux logements différents. Lors d'un premier essai sans cette règle, environ 20 % des DPE appariés servaient à plusieurs ventes. En examinant ces cas, il s'agissait surtout d'appartements différents d'un même immeuble, de surface proche, qui recevaient le DPE d'un voisin, et donc parfois une mauvaise étiquette. Quand deux logements différents visent le même DPE, celui-ci est attribué au logement qui lui correspond le mieux. C'est la contrainte habituelle de l'appariement entre deux fichiers (Binette et Steorts, 2022). En revanche, plusieurs ventes d'un *même* logement peuvent partager le même DPE : un appartement acheté en 2022 et revendu en 2024 peut l'être avec le même diagnostic, toujours valable. On reconnaît qu'il s'agit du même logement grâce à DVF : même parcelle cadastrale et, pour un appartement, même numéro de lot de copropriété. Au total, 21 706 DPE sont partagés par plusieurs ventes d'un même logement, soit 43 628 ventes. Les ventes d'un même logement à moins de 30 jours d'écart, souvent le même jour et à des prix différents, sont en revanche signalées à part (7 373 ventes) : il s'agit le plus souvent de cessions de droits partiels, comme une part d'indivision ou la nue-propriété, dont le prix ne reflète pas la valeur du logement entier. Zitouni (2025) écarte de même les ventes trop rapprochées d'un même bien.
6. **Les cas ambigus sont signalés, pas tranchés au hasard.** Il arrive que plusieurs DPE conviennent presque aussi bien, avec des étiquettes différentes. C'est surtout le cas dans les immeubles où plusieurs appartements ont des surfaces voisines : les bases n'indiquent ni le numéro ni, dans DVF, l'étage de l'appartement. La vente est alors marquée comme « ambiguë ». Cette règle suit la théorie de l'appariement de Fellegi et Sunter (1969), qui distingue les paires sûres, les paires possibles et les non-paires. Chareyron (2026) écarte de même les adresses ambiguës, sauf quand tous les DPE de l'adresse ont une surface et une étiquette proches. À l'inverse, quand tous les DPE possibles portent la même étiquette, la vente n'est pas ambiguë pour notre question : on ne sait pas quel DPE est le bon, mais on connaît la lettre. Ces ventes sont donc conservées.

Enfin, on écarte les DPE dont l'adresse a été mal reconnue par la Base Adresse Nationale (note de fiabilité inférieure à 0,5), car leur position n'est pas sûre.

4.5 Le résultat de l'appariement

Après nettoyage, la base compte 3 202 384 ventes de logements dans 93 départements, de 2022 à 2025. Nous avons retrouvé le DPE de 1 571 690 d'entre elles, soit 49,1 %. Nous appelons ces ventes les « ventes appariées ». Le taux augmente avec les années : 36 % en 2022, 51 % en 2023, 56 % en 2024 et 57 % en 2025. Il est plus élevé pour les appartements (59 %) que pour les maisons (41 %).

Un appariement entre deux fichiers administratifs n'est jamais complet. La littérature sur le sujet distingue deux types d'erreurs : les paires manquées, quand deux fiches du même individu ne sont pas reliées, et les fausses paires, quand on relie à tort deux fiches différentes (Harron et al., 2017 ; Doidge et Harron, 2019). Les paires manquées viennent d'identifiants absents ou insuffisants, de différences d'écriture, d'erreurs de saisie, ou tout simplement de l'absence de la fiche dans l'autre fichier. Même avec des sources de bonne qualité, les études publiées n'atteignent pas 100 % : sur 2016 à 2021, Chareyron (2026) conserve 590 446 ventes sur 6 831 060, et note que les appartements sont plus difficiles à apparier. Dans nos données, c'est l'inverse, probablement parce que la surface Carrez des appartements se compare mieux à celle du DPE que la surface bâtie des maisons ; ce point reste à vérifier.

Dans notre cas, plusieurs causes se cumulent :

- **Le DPE de la vente n'est pas dans la base.** Les DPE réalisés avant la réforme sont restés valables après juillet 2021 : jusqu'au 31 décembre 2022 pour ceux établis de 2013 à 2017, et jusqu'au 31 décembre 2024 pour ceux établis de 2018 à juin 2021 (décret n° 2020-1610). Une partie des logements vendus en 2022, 2023 et 2024 l'a donc été avec un ancien DPE, absent de la base. C'est ce qui explique la hausse du taux d'une année sur l'autre. D'autres causes jouent aussi, puisqu'en 2025 encore, quatre ventes sur dix restent sans DPE.
- **Il n'existe pas d'identifiant de logement commun.** Sans numéro d'appartement, plusieurs logements d'un même immeuble ne peuvent pas être distingués. Les ventes concernées sont marquées comme ambiguës ou ne trouvent aucun DPE assez proche.
- **Les adresses et les positions diffèrent.** Une adresse peut être écrite différemment, incomplète ou mal reconnue, et les deux bases ne localisent pas les logements de la même façon. Certaines ventes de DVF n'ont pas de coordonnées.
- **Les surfaces ne concordent pas.** Quand l'écart dépasse la tolérance, la vente n'est pas appariée, même si le bon DPE existe.
- **Nos règles sont volontairement strictes.** Le délai de trois ans, l'attribution d'un DPE à un seul logement et le refus de trancher les cas ambigus réduisent le nombre de ventes appariées. C'est un choix : la littérature souligne qu'il faut arbitrer entre paires manquées et fausses paires, et que les fausses paires peuvent fausser les résultats (Harron et al., 2017). Nous avons préféré un échantillon plus petit mais plus sûr.

La conséquence est importante pour la suite. Les ventes non appariées ne sont pas perdues au hasard : les ventes de 2022 et les maisons, par exemple, sont moins souvent appariées. Harron et al. (2017) rappellent que ce type de sélection peut biaiser les résultats si certains groupes sont moins bien appariés que d'autres, et recommandent de comparer les fiches appariées et non appariées. C'est l'objet des premières étapes de l'analyse.

5. Méthodologie

L'analyse se déroule en trois temps. On décrit d'abord le marché et l'échantillon, à partir de toutes les ventes. On mesure ensuite le lien entre étiquette et prix, à partir des seules ventes appariées. On vérifie enfin que le résultat principal ne dépend pas des règles d'appariement. Cette démarche suit celle de l'étude de référence (Chareyron, 2026).

Les comparaisons entre étiquettes portent sur les ventes appariées, car ce sont les seules dont l'étiquette est connue. Les ventes rapprochées (règle 5) en sont exclues, car leur prix ne correspond pas à un logement entier. Les ventes non appariées servent à décrire le marché et à juger de la représentativité de l'échantillon.

5.1 Décrire le marché

Sur l'ensemble des ventes, on calcule le prix médian au m^2 par trimestre et par département. Le résultat est présenté par une courbe de 2022 à 2025 et par une carte de France, sur laquelle chaque département est coloré selon son prix médian. Ces deux figures donnent le contexte : niveau des prix, écarts entre territoires et évolution du marché sur la période.

5.2 Décrire l'échantillon

On calcule d'abord le taux d'appariement par année, par type de bien et par département. Dans le rapport, ce diagnostic tient en un paragraphe ; le tableau détaillé et la carte par département vont en annexe.

On compare ensuite, année par année, les ventes appariées et non appariées sur le prix médian au m^2, la surface médiane et la part de maisons. On compare aussi la répartition des étiquettes parmi les ventes appariées à celle de l'ensemble du parc de logements (SDES, 2022). Chareyron (2026) fait ces deux comparaisons ; nous les détaillons davantage. Les écarts constatés sont décrits dans le rapport et pris en compte dans l'interprétation. Comme dans l'étude de référence, l'échantillon n'est pas repondéré.

5.3 Décrire les ventes appariées par étiquette

Un tableau donne, pour chaque étiquette, le prix moyen et médian au m^2, la surface, la part de maisons et la répartition par période de construction. Il reprend la présentation du tableau 1 de Chareyron (2026). Une carte de France montre la part de logements classés F ou G parmi les ventes appariées de chaque département.

Une matrice de corrélation complète cette description. Elle croise le prix au m^2, la consommation d'énergie (en kWh/m^2/an), le rang de l'étiquette, la surface et l'année de construction. On utilise la corrélation de Spearman, adaptée à un classement comme l'étiquette et à des prix très asymétriques. La matrice montre en particulier que la consommation d'énergie est liée à l'âge du logement, ce qui justifie de comparer ensuite des logements de même période de construction.

5.4 Comparer les prix sans correction

Des boîtes à moustaches montrent la distribution du prix au m^2 pour chaque étiquette, séparément pour les maisons et les appartements. Une boîte à moustaches résume une distribution : la ligne centrale indique la médiane, et la boîte contient la moitié centrale des valeurs. Cette comparaison est brute : un logement classé A peut être plus cher parce qu'il est récent ou bien situé. Elle sert de point de départ à l'étape suivante.

5.5 Comparer des logements semblables (résultat principal)

C'est l'étape centrale. On forme des groupes de ventes semblables : même commune, même type de bien, même tranche de surface, même période de construction et même trimestre de vente. Le trimestre joue le rôle du mois de vente chez Chareyron (2026) : il neutralise l'évolution générale des prix. Dans chaque groupe, on calcule le prix médian au m^2, puis l'écart de chaque vente à ce prix médian, en pourcentage. On fait ensuite la moyenne de ces écarts pour chaque étiquette. Les groupes de moins de cinq ventes sont écartés, et la part des ventes conservées est indiquée.

Prenons un exemple, avec des chiffres donnés pour illustrer le calcul. Dans un groupe d'appartements de 40 à 60 m^2 à Nantes, construits entre 1950 et 1970 et vendus au premier trimestre 2024, le prix médian est de 3 000 euros le m^2. Un logement classé G de ce groupe, vendu 2 700 euros le m^2, se situe 10 % en dessous. Si, sur l'ensemble des groupes, les logements G se situent en moyenne 10 % en dessous et les logements D à 0 %, on conclut qu'à logement comparable, un logement G se vend environ 10 % moins cher qu'un logement D.

Les écarts sont exprimés par rapport à la classe G, comme chez Chareyron (2026), et par rapport à la classe D, qui se trouve au milieu de l'échelle. Chaque écart est accompagné d'un intervalle de confiance, obtenu en refaisant le calcul sur de nombreux échantillons de communes tirés au hasard (méthode du bootstrap). On tire des communes entières, car les ventes d'une même commune ne sont pas indépendantes. Un diagramme en barres présente, pour chaque étiquette, l'écart brut de l'étape 5.4 et l'écart à logement comparable.

Cette comparaison par groupes est la version descriptive des régressions hédoniques, qui expliquent le prix d'un bien par ses caractéristiques (Rosen, 1974). Chareyron (2026) utilise une telle régression, avec des effets fixes « commune et rue » et « mois de vente ».

5.6 Suivre l'évolution de 2022 à 2025

On refait le calcul de l'étape 5.5 pour chaque année. Une courbe montre l'écart des classes F et G par rapport à D de 2022 à 2025, avec sur l'axe du temps le gel des loyers d'août 2022 et l'interdiction de louer les logements G au 1er janvier 2025. Chareyron (2026) fait le même exercice sur 2016 à 2021 et n'observe pas de tendance nette. Si l'écart des logements G se creuse nettement, et que les intervalles de confiance de 2022 et de 2025 ne se chevauchent pas, on pourra dire que la décote s'est accentuée. Ce résultat sera présenté comme une coïncidence dans le temps avec la loi, et non comme une preuve que la loi en est la cause.

5.7 Vérifier le résultat principal

On refait le calcul de l'étape 5.5 avec un appariement strict : sans les ventes ambiguës (règle 6) et sans les ventes appariées par la distance (règle 2). Ces deux règles sont celles qui comportent le plus de risque d'erreur, et la seconde n'existe pas chez Chareyron (2026). Un tableau présente côte à côte le résultat principal et le résultat strict. Si les écarts restent proches, les règles d'appariement ne déterminent pas le résultat.

5.8 Prolongements possibles

S'il reste du temps, trois prolongements sont possibles. Le premier refait l'étape 5.5 selon les caractéristiques des communes tirées de l'Insee, comme la part de propriétaires ou la part de logements vacants. Le deuxième regarde si le prix baisse brusquement au passage de F à G, à consommation d'énergie presque égale. Le troisième reproduit la régression de Chareyron (2026) pour comparer directement les chiffres.

6. Premiers résultats

Des calculs exploratoires ont été faits sur un département, la Loire-Atlantique, pour tester la méthode. Ils portent sur les 42 272 ventes appariées par l'adresse, hors ventes rapprochées. Le tableau suivant donne l'écart de prix de chaque étiquette par rapport à la classe D sur l'ensemble de la période, avec et sans prise en compte de la période de construction.

Écart par rapport à D	**A**	**B**	**C**	**E**	**F**	**G**
Sans tenir compte de l'âge	+13,8 %	+10,3 %	+5,3 %	-5,3 %	-8,6 %	-11,1 %
À âge de construction égal	+0,8 %	+1,4 %	+0,4 %	-3,7 %	-7,2 %	-9,5 %

Deux constats se dégagent. L'avantage des logements A et B vient surtout de leur âge : ce sont pour la plupart des logements récents, et à âge égal leur avantage disparaît presque. La décote des logements G, elle, se maintient à environ 10 % à âge égal. Ces résultats portent sur un seul département et doivent être confirmés à l'échelle nationale.

7. Limites

Seules les ventes appariées sont analysées. Elles représentent 49,1 % des ventes, avec moins de maisons et moins de ventes de 2022 que l'ensemble. L'étape 5.2 décrit ces écarts, mais ne peut pas exclure une différence sur des caractéristiques que l'on n'observe pas.

Le taux d'appariement varie selon l'année. Il passe de 36 % en 2022 à 57 % en 2025, en partie parce que les anciens DPE, absents de la base, sont restés valables jusqu'à fin 2022 ou fin 2024. Les résultats de 2022 reposent donc sur un échantillon plus petit.

Les bases ne contiennent pas de numéro d'appartement. Dans un immeuble, le DPE retenu peut être celui d'un autre logement. Ces erreurs sont limitées par les règles 3, 5 et 6, et l'étape 5.7 vérifie le résultat sans les ventes ambiguës.

Les seuils d'appariement sont des choix. Les rayons de 20 et 60 mètres, les tolérances de surface et le délai de trois ans ne viennent d'aucune norme. L'étape 5.7 vérifie le résultat sans les ventes appariées par la distance.

DVF ne décrit pas l'état du logement ni les travaux réalisés. Une partie de la décote des logements mal classés peut donc venir d'un mauvais état général du logement.

Les seuils d'étiquette ont changé le 1er juillet 2024 pour les logements de moins de 40 m^2 (arrêté du 25 mars 2024). Une partie des petits logements a ainsi changé d'étiquette sans changer de consommation, ce qui peut brouiller l'évolution entre 2024 et 2025.

Le champ exclut l'Alsace, la Moselle et l'outre-mer. Les trois départements d'Alsace-Moselle ne figurent pas dans DVF ; les départements d'outre-mer ont été laissés de côté.

L'analyse est descriptive. Elle mesure des écarts de prix entre logements comparables et leur évolution. Elle ne permet pas d'affirmer que l'étiquette ou la loi en sont la cause.

Références

Articles et documents de travail

Binette, O. et Steorts, R. C. (2022). (Almost) All of Entity Resolution. *Science Advances*, 8(12).

Chareyron, S. (2026). The Valuation of Energy Efficiency Labels in the French Housing Market. *Urban Studies*, doi:10.1177/00420980251410866. Version de travail : TEPP, document de travail n° 2024-05.

Christen, P. (2012). *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer.

Doidge, J. C. et Harron, K. L. (2019). Reflections on Modern Methods: Linkage Error Bias. *International Journal of Epidemiology*, 48(6), 2050-2060.

Fellegi, I. P. et Sunter, A. B. (1969). A Theory for Record Linkage. *Journal of the American Statistical Association*, 64(328), 1183-1210.

Harron, K., Dibben, C., Boyd, J., Hjern, A., Azimaee, M., Barreto, M. L. et Goldstein, H. (2017). Challenges in Administrative Data Linkage for Research. *Big Data & Society*, 4(2), 1-12.

Rosen, S. (1974). Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition. *Journal of Political Economy*, 82(1), 34-55.

SDES (2022). Le parc de logements par classe de performance énergétique au 1er janvier 2022. Document de travail n° 60, Observatoire national de la rénovation énergétique.

Zitouni, S. (2025). On the Capitalization of Energy Labels on the French Housing Market. Document de travail, HAL, hal-04380709.

Textes juridiques

Décret n° 2020-1609 du 17 décembre 2020 relatif au diagnostic de performance énergétique et à l'affichage des informations relatives à la consommation d'énergie des logements.

Décret n° 2020-1610 du 17 décembre 2020 relatif à la durée de validité des diagnostics de performance énergétique.

Loi n° 2021-1104 du 22 août 2021 portant lutte contre le dérèglement climatique et renforcement de la résilience face à ses effets (loi Climat et résilience).

Décret n° 2022-1079 du 29 juillet 2022 relatif à l'interdiction d'augmenter le loyer des logements classés F ou G (gel des loyers à partir du 24 août 2022).

Arrêté du 25 mars 2024 modifiant les seuils des étiquettes du diagnostic de performance énergétique pour les logements de moins de 40 m^2 (Journal officiel du 20 avril 2024).

Sources de données

Direction générale des Finances publiques et Etalab. Demandes de valeurs foncières géolocalisées. data.gouv.fr.

ADEME. Diagnostics de performance énergétique des logements existants (depuis juillet 2021). data.ademe.fr.

Insee. Base du comparateur de territoires. insee.fr.